

1 Dars.

Large language Modellarga kirish.

Language Model. LM $\rightarrow$ Bu keyingi so'zni ehtimollik asosida bashorat qiluvchi statistik model. Kirish matni oladi va eng ehtimoliy keyingi so'zni chiqaradi.

Large Language Modellar. LLM $\rightarrow$

$\downarrow$ massiv data setlar (kitoblar, xeb, maqolalar) ustida o'qitilgan milliard trillion parametrlar ilgor LM katta NNGali guruh

Sifatli generatsiya, va muloxaza qurish qobiliyati ega GPT-4.

LM $\rightarrow$ Bu statistik model bo'lib kontextga qarab ketma ketlikdagi keyingi so'zni bashorat qiladi. U ehtimolliklar bilan foydalanadi. matn ma'lumotidan

Erzanasi va avtomatik to'lovchi

Input text $\rightarrow$ model $\rightarrow$ bashorat qiluvchi

keyingi so'z.

Katta til modeli (LLM) bu LLM ni
kengaytirilgan versiyasi milliardlab
yaxshi tizimlarni parametrlarga ega bo'lgan,
ulagan data (kitoblar, veb-saxifalar, mazmunlar)
testida o'qitilgan model.

Katta xaraj tuzayli LLM yuqori darajada
generatsiya va mulohaza qilish qobiliyati
ga ega bo'ladi.

Token vs SÖZ.

Inson matni sözlari sifatida ko'radi.
I Love the Beach.

4 ta söZ. Ammo model matni token
deb ataladigan bo'laklarga bo'lib
qabul qiladi.

Qora qutoli kuzatish.
10 yil oldin model odam yaratishni
Xo'zir GPT 4 API $\rightarrow$ prompt engish
koponali modelga qora qutoli sifatida
qaratilgan. Biliq kuzatish.

Frontier model.

Eng oxirgi eng kechli modellar bolib
Ulkan hisoblash klasterlarida bo
kompaniya tomonidan o'qitilgan
GPT-4 (1.8 trillion parametrlar)
bir marta o'qitish taxminan \$100
milliarddan ortiq turadi.

XAI Colossus klasterida 200,000
ta H100 GPU bor xaridari 30,000\$

Bu pulga ega bo'lmagan odamlar
ulduz yechim. Kichik mashabada
millionlab parametrlilik LLM qurish.
Va o'qitishni o'rganish. So'ng kichik
mashabada natijalarni quraymiz
katta mashabaga ko'chirish. munamun.

Bu shaxs qurilmagani bolgan arxitek-
torga o'xshaydi. "xarid shaxs qurilmagan",
lekin. Kichik modellarni
o'rganish arxitektura tushunib kelish
asl loyiha analizi oshirish.

Transformer LLM yuvasi

LLM ning ichi turlishi Transformer
texshiruvchi ushbu at qadamlari or
tashiruvchi

texshiruvchi orqali en bedolat toqish
Sharega o'zgaradi.

Har bir blok 2 ta o'sha qismdan
iborat.

Self attention / ayta buyurish
har bir token boshqa tokenlarga
qarab ulan o'zgaradi: bog'liqlik
hisoblayotgan Query / Key / Value
mekanizmi.

MLP layer, (fast forward network)
bu qism har bir tokenni alohida
qayta o'zgaradi (non linear processing
feature extraction).

Bu icci qadam orqida residual
connection (qoldiq ulanish) bor
bu ma'lumot qayta o'zgarishdan
qayta o'zgaradi.

Kichik model fatta model
Kabi xarakat qilmaydi
Flop NN computing evaluate metric
GPT 3 $3.14 \cdot 10^{23}$ FLOP.

1. Mexanik uch turlagi bilim
bu aniq o'rganib bolarligan qismlar.

Transformer (LLM arxitekturasini)
Attention, Tokenizer (matnni IDga o'zgartiradi)
ADAM (optimizer)

2. Fikrlash tizimi haqida bir Flop uchun
maksimal intellekt olish

The bitter lesson
Qayta talqin.
Y. Ko'proq compute dastur global qidiradi
to'g'ri algoritmlar ahangdastir
fagat GPU qo'shning olgan fikr
noto'g'ri. To'g'ri talqin mashtab
algoritmik samaradorlik qidir.

Asosiy Optimizatsiya

Muamasi:

Compute (Flops) qanday parametrlar
qanday bo'lsa, qanday batch size bo'lsa
Data, sifat sifatli danan

Xotira (VRAM) aniqli

GPU / TPU

Insoniy kuchi,

1948 Til modelli.

1948 Claude Shannon

2003 Neuron LM

embedding tushunchasi; Bengio

2015 Attention Bah danan

2017 Transformer Bartha LLM.

2018 GPT₁

2020 GPT₃

2022 ChatGPT RLHF

Transformer Arxitekturası.

Attention mexanizmi Output

Weight bilan qoraqaynatilgan

Bank sözi tarjuma qilishda

attention doriga yoki pul sözlari

körüb to'g'ri nashoni aniqlash uchun

Transformer arxitekturası:

köp boshli self attention + MLP qatlar

filmlar qal joylari va boshqa

token parallel bizroqda ishlaydi.

Attention layer. Barcha token o'zaro bog'liq.

bog'liqligi. Kontekstni tushunish

MLP layer Har bir token tasvirini

mustaqil ravishda bilanzlaydi.

Open AI yangisi.

Chindilla zamon.

Optimal o'g'itish tokenlar soni ~~20 x~~
parametrlar 20 x 200 bolani

2022 yilgacha tusharisi bo'lsa,

SPT-3 125 B parametrlar = 300 B to'g'ri
Chindilla 3.5 T.

Alignment - UMi faydali zamon: shablon.

Attention input turli g'ismlari weight beriladi

BPE - Byte error Encoding

Chindilla law

De duplication

Token = Parametrlar 20 x.
fazorlari olib tashlanadi