

2 Dars Pytorch va Resuzs Hisob kitobi.

Ötgan Dars.

1. LM / LLM Til model, katta til model.
Matnida keyingi sōr (token) qanday olibish
boshqartiriladi.
2. Frontier Model - Hozirgi kunda eng kuchli
eng rəqəmsariv modello. GPT, Claude,
Gemini.
3. Emergence : Model kattalashganda
tōsatdan paydo bōlariqla qobiliyat
ozta sekin emes bir dān olibior.
4. Scaling Law Model olibhami
malumat va hisablash kattalashgān
sani qanday yaxshilashini kozaqla.
5. Bitter Lesson
6. Alignment Modelni xolal qawob
beridiga oqatla.

Token eng kichik birlilik LM uchun
Transformer self attention
ishlaydigan barcha CLM arxitekturalar
Flop hisoblash xarajati.

Token va Söz bir xil emas.

Odam sozlarni o'ziga ekin LM
matni token deb ataladigan kichik
bōlaklarga bōlib oladi. Biron bitta
Sōz bitta token bōladi. Tilga qarab
token xar xil bōladi

Ter taxmini Xisob

~~Clame~~ → Nap Kin Math.

Clame 70 B modelari 15 trillion token
va 1024 to 1100 GPU bilan bir necha
kun train qilish mumkin.

Kop o'ldi: Tensor hima?

Weight, gradientlar ^{Sozlar to'plami} Input matnlar
hammasi shu ko'rinishda saqlanadi
Sozlarni qanday saqlaymiz
FP32, FP16, BF16.

Komputer xar bir so'ni floatda saqlaydi
Saqlaymiz va formatni ikki narsa o'zgarishda
murosaga keladi. Qarab ko'raylik
kichik xar xil ifodalay diq.

Qandalik ishonli bo'lishi.

FP 32 eng ishonarli (aniq va keng so'z)
lekin ko'p qog'oz egallaydi.

FP 16 kichikroq, lekin, diapozon tor.
Ush sababli juda kichik sonlar
gradientlarni nobat qilib qiradi by
xato.

BF 16 dan kichik lekin diapozon FP 32

nikidom teng shuning uchun eng
kavga eng ko'p ishlatiladigan teng

ko'firani olib olingan xisoblash.

Han bir parametri uchun qanday
xotira ketidiri olib olingan xisoblash

muammas. elementlar soni x han birkotasi
gan Bayt. APAMK han bir parametri
aslında 16 bayt. xotirabermal qilib

chunki parametri o'zi uain gradient
va ikkala qishincha statistika
olloxibola sozlagan.

Activation va Ularini tejash.
Model hisoblash davomida, ko'plab
oralig' Matryslarni vaqtida eslab turish
chunqi keyinroq xatoni orgaga hisoblash
ular kerak bo'larsa. Model kattaligi
bu juda ko'p xotira yeydi.
Checkpointing usuli qo'llaniladi

GPU $\rightarrow$ Nega.

GPU xam hisoblash o'rali. Cenni GPU
buni 1000 marta tez qiladi. Chunqi
u parallel ishlaydi.

Bir xil ma'lumotni turlicha
ko'rish. Tensorning bir qismini olish.
yoki uni aylantirish, ko'p o'qilgan
masxa yozatmaydi.

Matritsani ko'paytirish.

DL da hisoblarning kattaligi
matritsani ko'paytirish. Bahor o'ralar
matritsani normalizatsiya qilish.

Model train uchun kodni hisoblashda
kopiratsiya xarajati hisobga olinmaydi.
Einops kodni tekshirishni yoritadi.

Hisoblash quvvatini oshirish.

Flops. bajarilgan hisoblashning
umumiy soni. Hoo farqida sekunda
988 trillion anal bog'lanish katta
modellar uchun 10²³ 10²⁵ korr.

Hech qanday GPU o'ling 100 joiz
tesligaga yetib olmagani loim bitar
vaqt bekunda ketadi. MEU

MFU haqiqatda har bir maristalida
ishlatiladi. 50 foizdan oshirish.

Forward Backward GNT

Forward (Matematik hisoblar) Backward
(xatoni taxli) Backward resurs
talab qiladi.

6 x Parametr soni x parametrlar

Model gander bo'ladik
Traindan oldin xights tozash
Sovlan bilan to'ldiriladi

Trainingdan oldin xisoblanishi
kerak bo'lgan 6 narsa.

Scaling laws.

1. Parametrlar. $12 \times L \times d^2$
 L = qatlar soni d = qatlar o'lchami
2. Xotira Sigati $16 B \times N$: 16 Bayt
ADAM va boshqa parametrlar saqlanish uchun
 $\times$ parametrlar soni Model ga xotira
3. Compute Budget. $6 \times N \times D$
 D = tokenlar soni 6 = media Flops $\times$ 4
4. Vaght. $6ND / GPU \times peak \times MFU$
5. Nisbat Soat $\times GPU \times \$$ soat.
6. Standartlik MFU ni oshirish BFI6
yuldarish checkpointing brekining soni