

A - Qism.

3 - Dars.

1. LM va LLM o'rtasidagi farq.

LM Matndan ceyingi s'z to'kenni bashorat qiluvchi
Statistic model. hagni istalgan bolishi mumkin.
LLM $\rightarrow$ milliard - trillionlab parametrlar ulkan
matn korpusida o'gatilgan chuqur NN asosidagi
LM. Asosiy farq mashtab va shu mashtab
tuzayli paydo boladigan emergent qobiliyatlar.

2. LLM va SLM farqi.

Small Language Model million milliard
parametr oraligida kamroq compute
bilan o'gitaladigan to'pinda to'z vazirlar
yoki resurs cheklangan quvri lmalarda
mohallangan model.

LLM milliard - trillionlab parametrlar keng
emergent qobiliyatiga ega ulkan compute
cluster talab qiladi Farq mashtab
umumiy qobiliyat kengligi: xotira / compute
talabi.

3. Bitter lesson.

Bich Sutton (2019) mashtabli umumiy xisoblay
foydalanuvchi AI usullari doim g'olaba yaratilgan
bilim yoki darsga xos aqilli fokuslardan ustun
To'g'ri talqin compute yetarli emas balki Natijada
compute x samaradorlik (Algorithm matters)

4. Claude, Chat GPT, Gemini qanday Model?
Bular frontier LLM lar aniqrog'i Transformer
arxitekturasiga asoslangan, SFT + RLHF
orqali aligned qilingan Inson niyatlariga
moslashtirilgan suxbat assistentlar.

5. Oilalarga kiruvchi asosiy modellar.
Chat GPT (Open AI): GPT 3.5, GPT 3.5, GPT 3.5 Mini
Claude (Anthropic): Opus 4.8, Sonnet 4.6, Haiku 4.5
Gemini (Google)

6. BPE nima?

Belgilar lugatidan boshlab matnning eng ko'p
uchraydigan qismini to'g'ri iterativ
ravishda birlashtirib yangi to'g'ri sifatida
qo'shib boruvchi tokenization algoritmi
GPT, Llama, Mistral barchasi BPE ishlatadi

7. Tokenization nima va nima uchun kerak?

Xon matnini NN gayta ishlay olasligan
butun son IP lariga aylantirish jarayoni
NN faqat sonlar bilan ishlaydi

Attention narxi ketma ketlik usulining
kvadratiga (n^2) proporsional yaxshi
Sizilgan tokenization computeri tejaydi

8. Training boshloqidan oldin nimalarni hisoblash kerak.

Bir vaqtda bir necha o'lchov: Compute (parameter, token, batch size) Memory (sifat, filtri, domen analizi) Xotira/VRAM Hardware GPU/TPU. Insoniy kredit (qaysi tajribalar ustuvorlik berish).

9. Model parametrlari soni qanday hisoblanadi

Har bir qatlamning weight matritsasi o'lchamlari. Linear qatlam $[d_{in}, d_{out}]$ bo'lsa $d_{in} \times d_{out}$ parametrlar beradi.

Butun model parametrlari barcha qatlamlar (attention, MLP, embedding) dagi shunday matritsalar yig'indisi.

10. Model uchun qancha xotira qanday hisoblanadi.

$Memory = num_elements \times bytes_per_element$

ADAM bilan har bir parametrga 16 bayt kerak $Weight(4) + gradient(4) + Adam\ m(4) + Adam\ v(4)$ hammasi FP32 da. Bundan tashqari activations har batch va sequence length bilan o'sadi, qo'shimcha xotira oladi.

11. Trade-off nima

Bir narsani yaxshi lash uchun boshqa narsadan vor kedish. b'g'i kelishi. Misol dynamic range vs precision (FP formatlar) memory vs compute (checkpointing).

12. Frontier model nima?

Eng oxirgi eng kuchli ulkan compute clusterlarda boy kompaniyalar tomonidan o'g'itilgan modeller (masalan GPT4 - 1,8 T parametr o'g'itish narxi \$100M+)

13. Emergent ability nima

Modelda ma'lum parametr chegarasidan o'tganda asta sekin emas birdan b'g'ida b'ladigan qobiliyat. Kichik modelda emera yoz katta modelda to'satib namoyon bo'ladi

14. Scaling Law nima.

Model sig'ati parametr (N), token (D) yoki compute (C) bilan quvvat qonunini sig'atida qanday yaxshilanishini ko'rsatuvchi empirik bog'lig'lik

$C = 6 \times N \times D$ kichik taq'ulaslar katta model nat-josini xarajatsiz beshorat qiluvchi model.

15. Chindilla qoidasi

Belgilangan compute byudjet uchun optimal o'qitish soni parametrlar sonidan 20 barobar ko'p bo'lishi kerak. ($D = 20N$)

16. Alignment nima

LMni inson niyatlariga mos, foydali, xavarsiz va halol bo'lishga yo'naltirish jarayoni.

Pre trained model o'zi faqat quyidagi token boshqariladi: - alignment orqali har qanday asistentga aylanadi.

17. SFT nima?

Pre trained modelni yuqori sifatli (prompt ideal javob) juftliklar ustida qayta o'qitish. Javob formati, ohang uzunligi.

18. Transformer arxitekturasini nima uchun muxim?

Faqat attentionga asoslangan (recurrence yo'q) barcha tokenlar parallel ishlanadi. attention barcha token juftlari o'arasidagi bog'liqlikni bir vaqtda ishlaydi. Bu parallellik tugayli katta mashtabda samarali o'qitish mumkin.

20. Flop nima

Kam sonlar ustida bajariladigan matematik amallar. Jami bajariladigan amallar soni.

21. MFU nima?

Sekundiga bajariladigan haqiqiy foydali model
Flops ning hardwarening nazariy peak
Flops ga nisbati. GPU dan qandalik samarali
pydani bayotjami ko'rsatadi.

22. BF 16, FP 16, FP 32 farqi.

FP 32 (32) eng aniq keng diapazon oltin standart
Elektron sexon. FP 16 (16 bit) tor dynamic range
katta modellarda kichik gradientlarda undozgalar
xaugla. BF 16 (16 bit) FP 32 bilan bir xil dynamic
range kamroq aniq. overflow/underflow
bo'lmaydi. Xatira FP 32 ning teng yonari.

24. Xavier initialization nima uchun kerak?
Weightlarni $1/\sqrt{d_{in}}$ ga shkalangah taqsimotdan
boshlaydi. Oddiy $N(0,1)$ bilan boshlangan signal
optlamalar portlab ketadi.

25 Activation checkpointing nima?

Parda activationlarni saqlash o'rniga ularning
bir qismini saqlab qolganini backward
paytida qaytadan hisoblash
Computing xot. mo. tejashga almashtiradi.
Katta modelarni GPU xotirasiga o'g'itish
uchun zarur.

B- Qism.

1. Nega kóp odamlar tayyor modellardan foydalanishga qaratilgan?

Frontier model qurish endi ulkan resurs talab qiladi. (GPT-4 darajasi; \$100M +, 200,000 GPU lici cluster 6 Milliard \$. Bunday resursga faqat bir necha yirik kompaniyalar ega. Shu sababli aksariyat odamlar noldan o'qitish o'rniga tayyor model API sini yoki prompt engineeringni ishlatadi bu qora quti muammasini keltirib chiqaradi.

2. Scaling Law va Chinchilla farqi.

Scaling Law umumiy qurilmagan model sifatini N, D yoki C bilan qanday yaxshilashini tavsiflaydi. $C = 6ND$. Chinchilla aniq xulosalar berilgan C uchun N va D qanday nisbatda bo'lishi optimal ekanini ko'rsatadi. $D \approx 20N$ yoki Scaling Law umumiy freymvork. Chinchilla endan keyin kelib chiqqan optimal balans.

3. Nega data sifatini/miqdori LLMda boshqa AI modelidan farq qiladi?

LLM ulkan xilma xil manbalardan (Common Crawl) o'qitiladi. Bax internet matnining aksariyati past sifatli (spam, takror, fofse) filtrlanmagan model noisga o'rganib o'qiladi.

Compute behuda ketadi LLM mahtobi shu qadlar
tattare sifat tasiri kuchragoli. sigatur. 2x
oshirish hajmi 10x oshirishdan ko'proq foydala
beradi.

4. Token va so'zlar doimo bir xilmi.

Yog. Character level: kitob $\rightarrow$ 5 ta token

har harf alohida. World-level kitob $\rightarrow$ 1 ta token.

lexin lugatda yog so'z UNKga aylanaol. naxo

yogoladi. BPE tez-tez uchraydigan bo'lak

$\pm$ token. (kitob $\rightarrow$ $\pm$ token) kamdan kam

so'z - bir necha bo'lak (don't = do + n't 2 token)

Demak bitta so'z bazon 1 bazon bir necha
tokenga to'g'ri keladi.

5. Parametrlar keyingi hisob kitob (compute
vaqt, narx, samaradorlik). bog'lanishi.

Zanjir: Parametr (N) + Token (D) $\rightarrow$ Compute (C)

$C = 6ND \rightarrow$ Samaradorlik (MFU) orqali

Vaqt = $C / (\text{GPU} \times \text{Flop/s} \times \text{MFU}) \rightarrow$ Narx (GPU

soat narxi $\times$ kerakli GPU soat). MFU past

bo'lsa xudoli shu compute uchun ko'proq

vaqt va ko'proq narx ketadi hammasi bir birga

bevosita bog'liq.

6. Kichik / katta model xotfi harakati farqi
Attention vs MLP Flops.

Kichik modelda 100M attention va MLP Flops
taxminan teng. attention optimizatsiya
sezilarli farq qiladi. Katta modelda
100B + MLP Flops attentionda andakatta
attention atiga 5 foiz compute oladi.

uni optimallashtirish oleyanli ohamiyatda
xulosa mashtab o'zgarishi etibor qarantish
kerak bo'lgan joy ham tubdan o'zgaradi.

7. Har bir Flop uchun maksimal intellekt nega
CS 336 markazida.

Zamonaviy AI ning asosiy dardlari eroli joyga
emas, resurs (compute, pd, vaqt) Har bir
dizayn qarori bu Flop ko'progi intermed
beradimi? savoliga tushadi. bu eng katta
model qurish emas chetlangan resursdan
maksimal Natija olish falsafasi. Bitter lesson
va chinchilla g'ommi asari.

8. Open AI ning hozirgi innovatsiyasi texnikni
yoki falsafasi.

Falsafiy (strategik qaror) Patil: Transformer
Google 2017, Adam 2016, Attention 2015.

Katta pre training (Bert, Elna; Google / Allen
2018 bardasi: open AI dan oldin natijalar)

OpenAI ning gipotezasi: katta data setda
o'qitilgan katta model umumiy intellektga ega,
va u bilan shunga zangabaturilarda faqat u yordam
mashtabida amal qilishadi. Zilaba ixtiro etish
birinchi bo'lib aqressiv mashtabdan
kelib chiqadi.

9. Nega GPT 3 Chinchilla nuzgari raqarishdan
under trained.
GPT 3, 175 B N, saqat 300 B D (1,7 token / Para)
Chinchilla optimal nisbati 20 token / Para
Yani 3.5 T token verak edi. Token yetarli
bo'lmagani uchun kudda shu compyuterni
to'g'ri taqsimlaganda erishilgan sifatga
to'liq yetmagan.

10. BPE nega character / word leveldan
ayzal.
Character level ketma ket juda uzun, attention
harxani oshiradi. Word level lugat cheklangan
kottalashgan yangi so'z UNK aglomasi.
BPE (kalaninmay) azzalligi birlashtiradi
cheklangan lugat (50k) UNK yo'q. Subword
bo'linadi. O'tada ketma ketlik amariy
Yaxshi siqish.

11. Nega FP16 xavfli, BF16 xavfli -1P-8 misol.
FP16 da exponent kam (5bit) dynamic range
tor ($6e-5$ dan boshlanadi, $1e-8$ tabi ke an
gradient bu deganlardan past anigi nolga
yunaloghladi gradient signal yozgalarini
BF16 da exponent 8 bit FP32 bi laq bittol
 $1e-8$ to'g'ri saqlanadi.

12. GND (6NT) formulas: gogardan kelib chiqish
Linear layer $y = xV$ uchun forward = $2 \times B \times D \times K \times F_{\text{forward}}$
Backward 2 ta matritsa talab qiladi dL/dV
va dV/dx har biri $2 \times B \times D \times K$ fami Backward
 $4 \times B \times D \times K$

13. MFU nega hech qachon 100% ga yetmaydi
Bil nedda chekla birga tasi: gilaori memory bandw
multi GPU communication overhead
kernel lthor overhead natogri fraktsiya.
non mutual smallon layerhorn sozlanadi
Shu sabablar doim bizni qizayitayotgan 50%

14. ADAM Vda nega har parametrga 16 bayt.
4 komponent har biri FP32 (4bay) Weight modelda
o'zi gradient backward natijay. Adam m
gradientni o'tmish yozaladi. Inomet
Adam gradientlar o'tmish, cottalet
2 moment adaptive LR uchun $4 + 4 + 4 + 4 = 16$

15. Xotira 8 GPU ga sigmaza (OOM) yekinlari.
Activation checkpointing (qayta hisoblash)
mixed precision BF16 (xotira yarimiga)
gradient accumulation kichik batch bilan
effective katta batch olish
Sharding (ZeRO / FSDP - model / gradient)
optimizer statini GPU lar o'rtasiga bo'lish.
batch size ni length ni kamaytirish.

16. MFU (precision orqali narxni kamaytirish)
Zararlar miqdori.

MFU 20% dan 50% ga oshirilsa bixitil

compute uchun vaqt 2,5x qisqarmadi.

$$V_{\text{aqt}} = C / (GPU \times Flops \times MFU)$$
 FP32 o'rniga BF16

ma'lumotni 1,5x tezlashtiradi.

17. Emergence kichikdan katta modelga ekstrapolyatsiya qilib bo'lmashligi amaliyotda himni anglatadi.

SLM da (masalan B) qobiliyat oshlamosa bular daxam oshlamoqda degani emas. Parametr osh

utilizatsiyada paydo bo'lishi mumkin.

Shu bilan birga kichik modelda o'qitilmoqda

utilizatsiya paydo bo'lishi mumkin, katta model

katat dargah mumkin dargah ekstrapolyatsiya

18. RLHF da reward model roli va o'qitish

Reward model - matnni baxolab unsoi xarakteristik baxolaguchi degan talqin bilan diqqatga olinadi. O'qitilishi bir prompt uchun 2 ta javob Anna tutor va co-shatiboladi. Anna tutor yordam beradi $\rightarrow$ prompt javob A javob B va shu reward model o'qitiladi. Keyin RL bosqichida LLM shu reward model bilan taqqoslanib maksimal ballni oladi.

19. SFT ning qanday o'qituvchi namunani o'qitish imkoniyati.

O'qitiladi: javob formati, ohang, uzurlilik, xarakteristik nuqta

O'qitiladigan. Yaxshi va yomon javob o'rtasidagi nozik ajratilishni, chunki bir prompt uchun faqat bitta namuna javob berilganligi yozilgan. RLHF

20. Pretraining va fagorati assistent o'qitish gap.

Pretrained model faqat statistik reyting token boshqaruvchi; $2+2=4$ request $4.3+3=6.3$ deb natijani davom ettiradi. chunki u yotli javob berishni o'z ichiga oladi. Gap 2 boshqaruvchi qoplash. SFT + RLHF
Pretrain = Reinforcement, SFT faqat, RLHF faqat