

5 Dars.

Takror bosh.

Embedding nima?

Discrete, categorical ma'lumotlarni ko'p o'lchamli sonli vektorga (High dimensional Continuous)

Floating point Vektorga o'tkazish asosidir.

Masalan, Ular 3.7 1 to'g'ri 4096 o'lchamli

Genini 3022 o'lchamli vektor bilan ifodalaymiz.

Nega LLM textni emas Mathni tushiradi?

NN matritsa ko'paytmalar va hosilalar

orasiga matematik operatsiya Ular matritsalar harflar ustida ko'paytirish va qo'yish amallarini bajarolmaydi.

Matn vektor shakliga o'tkarchi so'zlar ko'p o'lchamli space ingizlarga aylash.

Semantic Distance Matritsa masofasi va tanas vektorlari o'zaro bog'liq.

Distributed Representation Vektoridagi 4096 ta sonlardan har biri alohida bitta savolga javob bermaydi. Aksincha so'zning namini 4096 ta son bo'ylab tarqalgan bo'ladi.

Attention nima?

Attention bu NN formoqning barcha tokenlar orasidagi o'zaro aloqadorlikni va bog'liqlikni hisoblovchi matematik mexanizmdir.

Variatsiya $\Rightarrow$ Embeddingdan kelgan kontekstsiz bog'lanmagan statik vektorlarning ma'lumotdagi atrofdagi sozlarga qarab namoyishi aniqdan dinamik kontekstual vektorlarga.

Layer o'zi nima?

NN layer bu kirish ma'lumotlarini Weight va bias yordamida kleying; bosqichda o'tkazuvchi matematik amal

$$y = f(x \cdot w + b)$$

~~1.1~~ Transformer layer nima?
2 ta Asosiy Prigateli Attention vs FFN
Transformer blokida 2 ta multilogo turli
Ekan bir-birini to'ldiruvchi mexanizmlar.
Transformer Block dual engines.

1. Attention layer

Tokenlar bir-biri bilan gaplashadi
konteks bog'liqlikni aniqlaydi
barcha tokenlar bog'lanib aylanib o'tiriladi

2. Feed Forward Network

Har bir token mustaqil ravishda gapga ishlashadi
Model xotirasi va statistik bilimlarni saqlaydi

1. Attention layer. Context Engine.

Tokenlar orasida g'aribona aloqasi sodir
Tokenlar bir-biri bilan sozlashadi

Biz xonadagi talabalarning guruhdoshlik
munozara qilishi va fikr almashishi.

2. Feed Forward Network FFN layer.

Token vertical va mustaqil ravishda gata
chilarnadi. Har bir token vektora o'ziga
kengaytiriladi va sig'ibadi

$d \text{ model} \rightarrow u \neq \text{model} \rightarrow \phi \text{ model}$

FFN bu modelning g'arib xotirasi (memorized
facts) foydalanayotgan maycardlar. Model o'rgan-
gan darsga bilimlarini nasoslay Toshkent
darsga FFN layerining W_1 W_2 vektoralari.
Talabalar munozaradan song xonadida
otib olgan malumatlarini o'zligida
tahlil qilishi va xotirasiga muvazash.

Block architecture
Serial vs Parallel.

Serial (GPT-3, Llama, Mistral)

Input $\rightarrow$ [Attention layer] $\rightarrow$ FFN layer
 $\rightarrow$ Output

Parallel Architecture (Palm, Falcon)

Input $\rightarrow$ [Attention layer
FFN layer] $\rightarrow$ Output

1. Serial block Dastlab Attention o'tadi natijade olindi va FFN ga yaratildi. Bu klassik va eng bargavor usul.
2. Parallel Block Input bir vaqt o'zida ham attention ham FFN ga yaratildi. Ikkala natijasi qo'shilindi.
$$y = x + \text{Attn}(x) + \text{FFN}(x)$$

GPU hisoblash vaqtida kernel fusion hisobiga 15% 20% tezlashuv beradi. Kamchilik katta miqdordagi tezlashuv beradiganliqda yozilgan paradijga e'tibor.

DL da Normalizatsiya nega kerak?
DL da MN da 80-100 ta layer
olatida o'tayotganda ularning g'iyati
feda o'ta o'sib ketishi Exploding
Gradients yoki nolga yaqinlashib
ketishi. (Vanishing Gradients) yoki
Normalizatsiya bu xon bir qatlamni
aktivatsiya g'iyatlarini ma'lum bir
tartib diapazonida masalan 0 va 1
ushlab keram scaling usulidir.

* Layer Norm (GPT-2, GPT-3) eski standart.

Matematik martigi: Layer Norm har bir token vektore uchun o'rtacha qiy met. (Mean μ) va dispersiyaning Variance σ^2 hisoblaydi.

Huammas har bir token va har bir gat lam uchun Mean (μ) va Variance (σ^2) hisoblash GPU uchun o'rtiqcha hisoblash Compute va VRam rotiraga muvofiq. Katta Llm larda xatirlar sekinlashib olib ketiladi.

RMS Norm (Root Mean Square Normalization)

Llama, Gemma, Mistral Zamonaviy Standart Mega usmonaralidir. RMS Norm normalizatsiya asosiy foydasi: Mean (μ) ni ayirish talablashda emas. Balki vektor miqyosini Root Mean Square orqali mashtablashda

GPU tezli 10 ~ 50% oshadi.

Activation functions / Reasoning

Linearity $\rightarrow$ Non Linearity

Agar NN activation function bo'lmasa yuzlab layerli modelni shuncha katta katta chiziqli tenglamaga $(y = W_3 \cdot (W_2 \cdot (W_1 \cdot x))) = W_{net} \cdot x$ aylantirib qoladi. Chiziqli tenglamalar murakkab martigiy muammasni yechish gipoteza qilish va Reasoning qobiliyatiga ega bo'la olmaydi.

Activation function NNga non-linearity bag'ishlagadi.

Relu $\rightarrow$ Geler $\rightarrow$ Sig LL.

Relu $f(x) = \max(0, x)$

Har qiy qiy matlarni shartta 0 ga teng bo'lsa.

Ma'muro Dying Relu (Neuronlar butunlay o'tib)

Gelu: $Gelu(x) = x \cdot P(x <= x) = x \cdot \Phi(x)$

Sillig ehtimollikga asoslangan

Har qiy qiy matlarni, kichik sillig qiy qiy bo'lsa

Sig LL: $Sigmoid(x, y, z) = \text{Sigmoid}(x, y, z)$

* $y(VTC)$

Zamonaviy CLM larning eng kuchli Activation functions. Geste linear Unit usuli

Ikki xil dizignli o'zgartirishning asosiy paydmasi o'z bo'ron.

Relu: Har qiy qiy matlarni 0, musbat bo'lsa * Neuronlar qiy qiy o'zgan mavdigan bo'lib qiy qiy Relu.

Gelu Ehtimollik fag'irnat, Har qiy qiy matlarni ham kichik gradientlar saqlash qiy qiy

Sigmoid - Ushundaki bitta funksiyaga asoslanib, balki Geste mexanizimlar. Bitta neuron yoki malumatni yetkazishni boshqa ikki-dikki asosiy qiy matlarni olib o'tadi.

Nega hamma Suvizluga o'tdi Modellarining
mantigini fikrlash (reasoning) to'g'ri yozish va
matnini yechish aniqligi kescik oshirgani
empirik isbotlangan.

Transformer Architecture

Variants of KV Cache Optimization

A: Problem: Uzun Matnlarda GPU xotirasining
tolib ketishi.

LLM matn generatsiya qilayotganda
(Inference vaqtida) har bir token uchun
o'tgan barcha tokenlar key (k) va Value(v)
vektorlarini qayta hisoblanadigan uchun
ularni GPU VRAMda KV Cache sifatida
saqlaydi.

Xotira Muammasi: Matn Konteksi 4K dan
32Kgacha 128K ga o'sganda Cache hajmi
eksponentzial oshib ketadi. Natijada GPU
(OOM) xotasi beradi yoki model jadval
bekinovshadi.

B: Pre Norm vs Post Norm tartib
o'rnatiladigan farg.

Post Norm (classical Transformer)

Input $\rightarrow$ Attention / FFN $\rightarrow$ (+) $\rightarrow$ Layer Norm $\rightarrow$
 $\rightarrow$ output.

Pre-Norm (Temporary LLM)

Input $\rightarrow$ [Layer Norm] $\rightarrow$ [Attention / FFN] $\rightarrow$
 $\rightarrow (+)$ $\rightarrow$ output.

Post Norm gradientlar chugun qadrlanib yetib bormay beshoridek bish dizayni Trade udun juda xatiralar xorm up kichik LR talab etadi.

Pre Norm $\rightarrow$ Normalization Attention / FFN amallardan amalga oshirilad.

Ajralig: Residual connection mutloq odis va tono qolad. Gradientlar togrilar togru birindii qadrlanishga tosigisiz yetib bormay. Katta model borgan oqitishni olavon ettiradi.

Architecture Variants.

MHA MQA GQA ~~cash~~ tegon

MHA

Q Q Q Q Q Q Q Q Q
 | | | | | | | | |
 K K K K K K K K K
 V V V V V V V V V

Har bir Q uchun

Alloqada K va V bor

Aniq Recin VRAMni
 yetub yuboradi

MQA

Q Q Q Q Q Q Q Q Q
 \ / \ / \ / \ / \ / \ / \ /
 K K K K K K K K K
 V V V V V V V V V

Barha Q lar
 uchun yagora
 K va V

Ostadi arzan
 lekin aniglik
 past

GQA

Q Q Q Q Q Q Q Q Q
 \ / \ / \ / \ / \ / \ / \ /
 K K K K K K K K K
 V V V V V V V V V

Q lar guruxlasha
 har bir gurux

1 KV
 Oltir ortaliq
 Katiqa va
 Aniq qolavon

① Input Matn / Tokenlar

[3841], [1205] [1303]

Toshkent g'ozal shaxor.
Model tushunadigan
ragamli FPa ga bilan.

② Embedding + RoPe layer

Ragamli FPa

top o'larani vektor ga o'tirish.

Va soning gapolog; anig
o'ini belgilash (RoPe)

③ RMS Norm

Attention Layerga
kiritishdan oldin sonlarni
bir xil xavgsiz va motabil
oraliqga keltirish.

A. Residual
Stream - /

MHA qayada 8x ↓

④ Group Query Attention

Tokenlar bir biri bilan gaplog;
kontekstni va o'zaro bog'lanishni
aniglash

⑤ Output Projection (V=O)

Attention dagi ko'plab heads
toplangan aloxida malumatlar
tartibli vector ko'ziritilgach.

⑥ RMS NORM

FFN (Bilimlar omboriga kiritishdan
oldin Butani yanaki bar tartiblaydi)

⑦ SwigLU FFN (Knowledge Engine)

$x \times U_{gate} \otimes x \times U_{up} \rightarrow \text{Swish} \rightarrow U_{down}$

Modelning bilim saqlanadigan va
mantiqiy girdelari Reading
asosiy misol blok

⑧ Final RMS Norm

/LM Head

⑨ Output Tokens