

Savol Javob.

6 Dars

1. LLMda Layer nima?

NNda va LLMda layer bu biriktirilgan ma'lumotni o'rganiluvchi vaqtlar. matritsasi va matematik amallar (Attention, FFN, Normalization) orqali bog'itib o'yingi bosqichga uzatuvchi matematik o'zgartirishlar blokidir.

LLMda 100 lab layerlar bo'ladi. Har bir layer datani bosqichma bosqich abstractlashtiradi.

Quyidagi layer - grammatika sintaksisini

O'rta layer semantik bog'liqlikni

Yuqori qatlam mantiqiy va qaror qabul qilishni Reasoningni shakllantiradi.

2. Vocabulary va Tokenization ning farqi nima?

Vocabulary → Model biladigan va tushunadigan barcha unikal tokenlarning muqim ro'yxati va ularning ID raqam katalogidir. Masalan

Llama (Vocabulary) = 128,000 ta token dan iborat.

Vocabulary bu statik lugat kitob, Tokenization esa shu kitobdan foydalanib matnни bōlaklashtiradigan mexanizmdir.

Vocabulary inglizcha ushbu 100,000 sozli kitob, Tokenization Xatni olib lugat kitobidan foydalangan holda xatdagi sozlarni bitlarni bitlga topib raqamlab chiqaradi. Tarjimon varianti.

3. Tokenization nima va uning qanday turbari bor?

Bu uchlusiz matn oqimini PC va NV qayta
shay oladigan diskret kichik birliklarga
bölish jarayoni

3ta asosiy turi bor.

1. Word based. Sözlarga asoslangan. Matn bosh
joylar space bōgichga bōlinadi. Men, maktabga, bordim,
kamchilik. Usab lary hajmi juda katta, UNK xato:

2. Character based. Matn bitta bitta harflarga
bōlinadi. Kamchilik lugat juda kichik (100 ta harf)
Akin matn oqimda ketligi juda urayib ketadi.
Model semantika ma'nosini yoqotadi.

3. Subword - based → Zamonaviy Standart.

Tegam bor eng samarali usul. Sözlər ter-ter
uchraydigan ildiz va qo'shimchalar ga bōlinadi.
maktabdagilar → maktab + dagi + lar.

Asosiy algoritmlar: BPE → Llama Chat GPT

Word Piece + Bert, Unigram - Sentence Piece.

4. Layer qanday sub layer lardan tashkil topgan?

Standart va zamonaviy Transformer bloki

2ta asosiy matematik sublayer hamda ularni
ushlab turuvchi 2ta yordamchi mexanizmdan
tashkil topgan.

Transformer layer = [Normalization] + [Sub layer 1 -
Attention] + [Sub layer 2 + (Norm) + FFN] + [Norm]

SUB layer 1. Attention (MHA, HHCQA) Tokenlar
orasidagi gorizontal munosabatni va kontekstual
bog'liqlikni hisoblaydi.

SUB layer 2. FFN (MLP) Har bir tokeni o'ziga xos
ravishda alohida o'ylashni qayta bilim beriladi
layer.

Yoruban di 1. Normalization (P2 Norm, RMS Norm Layer Norm) Gradient portab ketmasligi: uduu hisobni mashtablog.

Jordaneri 2. Residual Connection (skip connection) Gradient sonmasligi uduu xirish signalini amallarni chetlab otkazib beradi. $x + f(x)$

5. Attention va FFN farqi nima?

Attention Layer $\rightarrow$ Token lara gorizontel aloqam (Time Dimension T) mesalaydi. Tokenlar bir biri bilan gaplashadi, konteks va marumi belgilyadi.

FFN layer. (Knowledge Engine) Tokenlarni mustaqil va vertical ravishda (Feature Dimension) qayta ishlaydi. U modeling Factual Xotiraga, Memorized Facts saqlaydi gap joqshir.

Merom	Attention Layer	FFN
Harakat yonalishi	Tokenlararo cross communication	Har bir token mustaqil
Vazifasi	Kontekstni shartlashtirish	Knowledge Engine
Matematik o'lcham	$T \times T$ (Sequence length)	$d_{model} \rightarrow 4d_{model} \rightarrow d_{model}$ (Hidderoi)
Real Analogiya	Guruh bo'lib munosabat	Kutubxona sharoiti orqali fakti xotiraga yuqalaydi.

6. Activation Function 7 Bu NNga non-linearity bag'ishlovchi matematik funksiyadir. U si'z 100 lab gatlari ham shunday shunday soddadirig'li matritsa $X = X \cdot W$ aylantirib o'oladi.

Relu $\rightarrow f(x) = \max(0, x)$
Marfiy qiymatlar $f'(x) = 0$ bo'lib Pying Relu.

Gelu $\rightarrow$ Ehtimollik tasvili qat'iy asoslangan sillig'li
 $f(x) = x \cdot \phi(x)$ Marfiy zonada sillig'li chizig'li
Sxig'li Zamonaviy Standart. U darvoza Gate va 3 ta matritsadan iborat.

Sxig'li $(x) = (\text{Swish}(x \text{ U gate}) \otimes (x \text{ Wup})) \text{ Wdown}$
Model Martiqiz Fikrlashi (Reasoning) va matematik yechish qobiliyati: keskin oshiradi.

7. LLM model arxitekturasini tushuntirib bering?

Zamonaviy LLM arxitekturasini - bu Decoder Only Transformer (masalan Llama 3, GPT 4) U odam ket joylashgan L ta bir xil transformer bloklarining zanjiridan iborat.

Input text $\rightarrow$ Tokenization

1. Matn subword ID zagonlarga bo'linadi.

2. Embedding + RoPe: Tokenlar d model o'lchanli vektor ga o'tariladi va kompleks texislarida bo'rish RoPe orqali o'zini belgilanaadi.

3. 3rd Transformer Block (Per Norm)

Avval RMS NORM qilindi.

GQA yigiladi

Residual Connection orqali kirish qisq.
 $X + \text{GQA}$

Yana RMS NORM

SU.GLU FFN orqali farketilgan bilvon
Ikkinchi Residual Connection

4. Final RMS Norm & Un embedding (LN Head)

8. Encoding va Embeddings ning farqi nimada?

Encoding Ma'lumotni bir formatdan ikkinchi formatga o'tkazuvchi umumiy qoida yoki algoritim. Unda xech qanday o'zgaruvchi Semantic ma'no bo'lmaydi.

Embedding (Vektorlashtirish) Discrete ma'lumotlarni ko'p o'lchamli ma'noali Semantic masofaga ega bo'lgan continuous floating point vektorlarga o'tkazishdir.

9. Trade off nima?

Biron parametrimni o'zgartirish uchun ikkinchi bir parametrimni qurib berish kerak. Buxoslar muvofiqdast.

MHA juda aniq GPU VRAM xotirasini qotib qo'yadi

MQA o'ta tez va tejamkor lekin model aniqsizlashib ketadi.

10. Qanday xolatlarda model toxtab qoladi?
LLM ni o'qitish jarayonida modelning biror-bir
ga buralishi Training Instability/Collapse
Quyidagi 4 ta asosiy sababga ko'ra yuz

beradi.

1. Exploding gradients. Normalizatsiya

2. Out of Memory (OOM) KV cache yoki Batch size
VRAM

3. Loss Spikes Data sifatisiz yoki faccoring

4. Underflow (FP16 ga Precision yetishmasligi)
Gradientlar 10^{-8} dan kichiklashganda FP16
formati ularni nolga tenglashtirib qo'yadi

II Attention va Attention layer orasidagi
farq nima?

Attention $\Rightarrow \text{Softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$ yoki texniklarni
orasidagi masala va a'g'irlikni hisoblovchi
mantiqiy alqoritm.

Attention layer Bu ushbu formuladan boshqani
o'z ichiga Linear Projection matritsani

MHA, BQA jarayoni Role position kodlarini
GPU xotirasini boshqaruvchi dastur to'liq
kod dasturi, modulidir.

12. Serial va Parallell bloklar o'arasidagi farqlar qanday?

Serial block (GPT-3, Llama-3)

Input $\rightarrow$ [Norm] $\rightarrow$ [Attention] $\rightarrow$ (+) $\rightarrow$ [Norm] $\rightarrow$ [FFN] $\rightarrow$ (+) $\rightarrow$ Output

Parallell Block. (Palm, F16)

$\rightarrow$ Norm $\rightarrow$ Attention

$\uparrow$
Input

$\downarrow$ $\rightarrow$ (+) $\rightarrow$ Output.

$\downarrow$ $\rightarrow$ Norm $\rightarrow$ FFN

Serial $\rightarrow$ Attention amaliy bajaradi natija olinadi
va u FFNga uzatiladi. O'ta bargazor.

Parallel $\rightarrow$ Attention + FFN bir vaqtning o'zida
parallel ravishda hisoblanadi. 10% 20% $\uparrow$

13. Nima uchun ReLU eskirgan?

Relu ($f(x) = \max(0, x)$) 3ta asosiy sabab.

1. Dying ReLU. training 30% 50% gradient oqib ketadi

2. Silliq emassligi

3. Zatiy mexanizm yozilishi. Saigili kabi zamonaviy aktivatsiyalar, geysi arxitekturalar, dinamik nasos o't qiladi. ReLU da bu imkoniyat yo'q.

13. Nima uchun RMS Norm yaxshi.

2019 yilda RMS Norm classical Norm o'rniga joq

Nega yaxshi?

1. Mean (μ) hisoblanmaydi.
2. GPU memory Bandwidth tejamdorligi.
3. Parameter kamayishi

15. MHA va GQA farqlari nima?

MHA $\rightarrow$ klassik usul Har bir query A boshi uchun alohida K va Value boshlari mavjud. Afsuslari juda ariz sifatli.

Bandligi KV o'tish xotirasini o'ta cheklanish
uzun kontekstda VRAM to'lib toxtaydi.

GQA Barcha Query boshlari uchun atigi
1 ta yagona Key va Value ishlatiladi.

Afsuslari Cosine Hojiri Niz barabar parametrlar
Generatsiya juda tezlashadi.

Model semantik hosil qilishni, arizlarini
yozishni muvaffaqiyatli.

16. MQA vs GQA qanday ustunlik beradi?

MQA (Atigi 1 ta KV) $\leftrightarrow$ GQA (Guruhlangan KV)

MHA (Har biriga 1 ta KV)

O'ta sekin

GQA o'ta tez

MQA	GQA	MHA
↓		
Öta tez past sifat	Ölfin orolig Tez + Anig	Öta sekin, yuqori sifat.

17. Distributed Representing
NN bitta alohida neyronlar emas balki
Vektorlarini yuzlab / minglar N birligi
taqalgan holda saqlash.

18. Reasoning nima?

LLM larda Reasoning - bu shunchaki keyingi
sinni yoddan topish emas balki bir nechta
mantiqiy bosqichlarni Chain of Thought
gipotezalarini solishtirish. Shartli qarorlar
qabul qilish. murabba mantiqiy va
matematik muammlarni bosqichma bosqich
yechish.

1. Swiglu Activation Function

2. Deep layers

3. RLHF / SFT & CoT Chain of Thought.