

8 Dars.

Training vs Performance Optimization.

LR and Warm up. Training boshida gradientlar portmasligi uchun LR qiymati last labai 1000 Qadarda $0 \rightarrow LR_{max}$ shkalasida sekin oshiriladi.

Gradient Clipping: Gradient vektori normasi oshib ketganda ($g_{max} = 1.0$) u qirg'ib qo'yilguncha aq holda $loss = NaN$ xatosi beradi va model buziladi.

Drop out = 0.0 (LLM golden Rule) Ulkan pre trained datasetlarda Dropout butunlay o'chiriladi. faqat Weight Decay ishlatiladi.

LLM architecture (Seq to State)

Decoder Only $\rightarrow$ Pre Norm + RMS Norm

Gradient oqini toza residual yoldan o'tishi uchun norma lixatsiya omallarda oldin bajariladi va Mean hisoblanmagan RMS Norm ishlatiladi.

SwigLLM RoPE and GQA

Hertizig sikrlash beruvchi SwigLLM aktivatsiya hisbiy position beruvchi RoPE va KV cache xotirasini 8 marta tejovchi GQA qollaniladi.

Nega Integer emas, Aynan Vector kerak?

Tokenizer matnini 40, 1842, 3552 degan butun sonlar (Integers) qilib berolmay nega model ga shuni o'zi yetmaydi

I love AI $\rightarrow$ Tokenizer $\rightarrow$ Integer IDs
BPE Algoritmi 40, 1842, 3552
Embedding layer NNlar bularni solishtira olmaydi.
 $\rightarrow$ Ute har bir ID
o'unga 768 ta float $\rightarrow$ Dense Vector
son oladi

1, 3, 768 Tensor
Attention va Math
amallari uchun tayyor.

Matematik sabab. Attention mexarizmi tokenlar
bir biri bilan gaplashish va ular o'rtasidagi
semantik bog'liklikni hisoblash uchun
Skalar ko'paytma A.K.T amallarni boyerbi
Integersni amallarda shartli iker Ular
kopaytirish yoki ayirish orqali Mono noma
batni topib bo'lmaydi.

Vektor Yedini: NNda platig poing 768
o'larani ko'p o'larani farosiy koordinata.

Word token Embedding vs Word Position Embeddings.

GPT-2 va klassik Transformerlarda
har bir token 2 ta alohida embedding
matritsaning yigindisi bilan hosil bo'ladi.

$$Wte(TokenID) + WPe(Position Index)$$

Wte (Word token Embedding)

Shape: Embedding (50257, 768)

Tokenning lugaviy semantik ma'nosini saqlaydi.
Lugatlarda: 50,257 ta tokenni har biriga

768 ta fildat son beradi.

WPe (Word Position Embedding)

Shakli Embedding (1024, 768)

Token idmlar tartibini (0, 1, 2) ko'rsatadi.

max 1024 ta pozitsiyani har birini

768 son beradi.

P_0	P_1	P_2
Odam	kitob	o'qildi o'qildi
P_0	P_1	P_2
kitob	o'qildi	odam.

Ikkala gapdaxun bir xil so'z ishlatilgan

Wte qiymatlar ayraun bir xil. Lekin WPE

Position vektor g'ildir.

Transformer foydalanishi ikkala gapdaxun

uslubiy va mantiqiy urf har xil ekanligi
muammolarni ajratib oladi.

1. LLM nega matnli sozlarni to'g'ridan to'g'ri o'qiy olmaydi?

NN faqat matematik va diqqatli analarni bajaruvchi reganli mashinalardir? Ular matnli simvollarini tushunmaydi, shu sababli matn avval reganli fikrlarga, so'zga floating point vektorlarga o'tkazilishi shart.

* One hot encoding orqali sozlarni reganlashtirib bo'lmaydimi?

Yo'q chunki, o'ta katta va siyqak matritsali hosil qiladi, bunda sozlar orasidagi semantic masofani mutlaqo ko'rsatib bera olmaydi!

* NN kiritilgan vektorlar integer bo'lsa nima bo'ladi?

Integer sonlar bo'yicha hosila (gradient) hisoblab bo'lmaydi. Backpropagation va Attention dot-product analarni bajarilishi uchun vektorlar uzluksiz float qiymatlardan iborat bo'lishi kerak.

2. Subword Tokenization (BPE) ning Word based va Character based tokenizationdan ajralishi nima?

Subword BPE lugat hajmini tekislashtirib ushlab turib 30K-128K lugatga yo'q normal soz UNK muammosini yozotadi va morfologik ifodalarini saqlab qoladi.

* GPT-2 BPEdagi '9) belgisi minami bildiradi
Space belgisi

* Nega ushbu matnlar GPT-2 to'xtirida o'ta
kop to'xtirlarga bo'linib qoladi.

Chunki GPT-2 asosan inglizcha to'xtirlarga
o'qitilgan. O'zbekcha so'zlar vocab. ssan iola yog'la
Sababli u so'zlarni karakter va byte darajasida
maydalab tashaydi.

3. Kte (Word token Embedding) layer vazifasi?

Kte - bu token ID raqamining uning lugatidagi
semantik ma'nosini ifodalovchi model

GPT-2 768 o'lchamli vektorga o'tkazib beruvchi
kopaytirish matritsadir. Embedding (50257, 768)

* Kte weightlarni o'qitish jarayonida
o'zgaradimi?

Ha, Kte matritsasi o'zgariluvchi parametrlar
hissoblanadi va Backpropagation jarayonida
gradientlar bo'yicha yangilab boriladi.

* Kte va Unembedding matritsasi o'rtasida
qanday bog'liqlik bor.

Koplab modellarda xotirani tejash
uchun Kte va LM Head vektorlari engilashtrilgan
buna Weight Tying deyiladi.

4 WPe (Word Position Embedding) nimağa xarak?

Transformer arxitekturası matnı parallel oʻqigan uchun tokenlar tartibini koʻrmaydi. WPe tokenning gap ichida mutlaq oʻrni $(0, 1, 2)$ vektorga aylantirib Embedding $(1024, 768)$

* WPE absolute Positionning qanday darajasi bor?

U fagat oʻzi (rair qilingan kontekst) kamiligida (1024 token) oʻqiladi. Undan uning matn boʻlisa ishlatilmas gʻoladi.

* Zamonaviy LLM WPe oʻrniga nima ishlatadi. WPe oʻrniga RoPe dan foydalaniladi.

5. Odam kitob oʻqidi va kitob oʻqidi odam Wte va WPE?

Wte (semantic) vektorlar teng boʻladi, lekin, soʻzlar oʻrni har bir boʻlgani uchun WPe (position) qoʻshiladi va Transformer maro farqini tushunadi.

Agar WPe ishlatilirmasa ushbu ikkala gap qanday idrok qilinadi?

* WPe boʻlmasa Transformer uchun 2 ta gap matn boʻlgan bir xil Bag of Word boʻlib qoladi va grammatik tartib yoʻqoladi.

* Nina uchun v_{te} va v_{pe} vektorlari
ko'rsatilmaydi balki g_{ost} bo'lib,
vektorlarni ko'rsatish ularning o'ldirani 768
saglab qoladi va linear proyeksiyadan
har ikki dastlarni parallel saglab imkonin
beradi.

6. HFda AutoTokenizer va AutoModel
farqi nima?

AutoTokenizer matnni tokenlarga bo'lib
ID sonlar beradi, AutoModel esa tayyor
NN w ehtimallikni yuksalib, ushbu ID larini
vektorlarga va matnigga o'tkazadi.

* AutoTokenizer.from_pretrained('gpt2')
chagirilganida qanday fayllar yuklanadi?
vocab.json, merges.txt (BPE qoidasi)
tokenizer-config.json va tokenizer.json.
* return - tensor = 'pt' parametri nimani
anglatadi.

Tokenizer natijani oddiy Python ~~roypale~~
list emas balki Py-torch Tensor obyektiga
o'tkazib berishni ta'minlaydi.

7. embedding, shape natijasidagi torch.size (1, 3, 768) nimani anglatadi?

1 - Batch size (1 tagap), 3 - Sequence length (3 tagap)
768 - Hidden dimension (d model har bir token vektori uzunligi)

* Agar Batch size 4 tagap va har birida 10 ta token bo'lsa qanday bo'ladi?

torch.size (4, 10, 768)
* GPT-2 dimensional sequence length nechaga teng? 1024.

8. Chinchilla Scaling law bo'yicha 124^{th} parametrli modelga qancha token qancha data kerak.

$D \approx 20N$ 2.48B 9.24GB data set.

* Agar 2GB parametrli Llama 3 o'g'itilgan chinchilla bo'yicha tanida qancha token kerak 7B x 20 140B

Amalda 15 Trillion token bilan o'g'itilgan.

* 1 token o'rnatish uchun boylar Inglizcha 4 byte.

3. HFold model. Safo tensors

Tagliriy va riza: nima?

U model vanlarin saglaadigan
davson terzor binary formatda
* BPT2 modelning safo tensor haymi
qaralar. 548 Mb

5. Tokenization va Embedding
ketma-ketligi.

Inson matni $\rightarrow$ Tokenizer BPE $\rightarrow$ Token ID $\rightarrow$
 $\rightarrow$ $W_{te} + W_{pe} \rightarrow$ Transformer Blocks $\rightarrow$
 $\rightarrow$ LM Head (softmax) $\rightarrow$ Keyingi token ID $\rightarrow$
 $\rightarrow$ Decode $\rightarrow$ Inson matni.

Xulosa.

NN and Math Rule: Transformer MV text yor
Integer ID rangarlarida eng soz va soz
Floating point Vector Tensorlarni bayt shakl
 W_{te} and W_{pe} Hammani. W_{te} sozlangi manna.
 W_{pe} uning goyadagi ozi.

Xozirgilar: Autotokenizer mata BPE ozi
ID rangar, Automodel esa ushbu ID
 $W_{te} + W_{pe}$ malizta ozi tochi size
(1, T, 768) shaklda katorga oylantirib
Attention bozorga ushbatoli