

10 Dars.

Tokenization $\rightarrow$ Matnni diskret butun sonlar
(input-ids) ketma ket lixda o'tkazish. NN matnni emma
float sonli indexlarni tushunadi.

Embedding Embedding: Indexlarni diskret tokenlar
va ularning o'rnini d model o'lchamli
differentiyalanuvchi zic float vektorga o'guri
($x_{te} + x_{pe}$)

Self attention Mechanism: Tokenlarning
kontersolagi o'zaro bog'liq va manooloshligini
olovayesini Query Key va Value orqali
hisoblash.

Embeddinglar x_{te} va x_{pe}

Nega Integer emas, Float Vector).

Inson tili diskret belgilar (stringlar) i'borat

NN tarmog' esa faqat uzluksiz differentiyala-
nubdir matritsa ko'paytlarini bog'lovchi

Token bergan Integer IDlar faqatgina
(40, 82, 120) shunday indexlar xalos.
Ularni o'zaro ko'paytirib xosila olib
bölmaaydi.

$x_{te} \rightarrow V \times d_{model}$ (50257 x 768) matritsasi

Diskret ID raqamni 768 o'lchamli
float vektorga o'tkazadi. U so'zniing lugaviy
Semantikasi ushlaydi.

Upe gapdagi soʻzlarni ketma ketligini
Transformer parallel ishlaganini sababli
tokenlarni ketma ketligi koʻrinmaydi. Upe
tokenning gapdagi oʻrnini koordinatlash-
tiradi.

Tensor shape torch.Size([1, 3, 768])

1 (Batch size) Modelga bir vaqtida uzatiladi.

3 (Tokens/Sequence length) Maʼnolarni tokenlari

768 (Hidden Dimension) har bir token maʼnisi
va pozitsiyasini saqlaydigan high dimensionli foyda

Attention va Conv1D(2304, 768)

Size (Mega 2304?)

Hugging Face GPT-2 implementatsiyasida,
standart torch.nn.Linear oʻrniga Conv
ishlatilgan.

Mega 2304? Chunki MHA ishlatilgan
qirish vektorini 3 ta mustaqil vektorlar
toplamiga Q, K, V proyeksiyalari 768×3 .

Q [1, 3, 768]

Input [1, 3, 768] Conv1D(2304, 768) → K [1, 3, 2304]

V [1, 3, 768]

Normalizatsion : Layer Norm vs RMS Norm.

NN da datalarni oqini-jilovlash uchun normalizatsiya zarur.

1. Layer Norm (GPT-2, GPT-3)

Har bir token vektori $x \in \mathbb{R}^d$ uchun o'rtacha qiymat μ va dispersiya (σ^2) hisoblanadi.

RMS Norm (2019)

O'rtacha qiymat μ hisoblash va $x_i - \mu$ suzish amallari model barga zorligi uchun murin e'lon. Faqat o'rtacha kvadratik Iloz (RMS) o'zgarish mashtablash yetarli.

$$RMS(x) = \sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2 + \epsilon}$$


Layer Norm (GPT-2) RMS Norm (Llama-SOTA)

Hisob kitob	Mean μ + Variance σ^2	fagat Root Mean Square
Learnable Par	γ (Scale) va β (Shift/Add)	Faqat β yoz
GPU	Yuqori overhead	10-50% $\uparrow$ par xotira
Math	$O(2d)$ amallar	$O(d)$ amallar.


Activation functions

Relu vs Gelu vs SwigLU.


Relu: $f(x) = \max(0, x)$



Gelu: $x \cdot \Phi(x)$



SwigLU: Gate Linear Unit



1. Relu Rectified Linuz Unit

$$f(x) = \max(0, x)$$

Kamchilik: Manfiy zomada $f'(x) = 0$. Train olgovanier
Nring 30-50% gayta turlan mas bo'lib
qoladi Dying Rele Problem.

2. Gelu (GPT-2, GPT-3)

Gelu input'ning qiymatiga qarab uni saqlab
qolish ehtimolligi Gauss

3. SwigLU (SOTA - Llama 3, Qwen 2.5)

GLU (Gated Linear Unit) oilariga mansub bo'lib
2ta chiziqli proyeksiyalarni elementar-element
kopaytmassiga (Gating mechanism) asoslanadi.

Nega SwigLU Mantiqiy Fikrlash (Reasoning)ni
oshiradi.

Wgate matritsasi eksport ogini olinanik
ravishda o'tkazuvchi Mantiqiy Darvoza (gate)
varigini o'taydi. U xcedeli MNdagi

if-Else shartli mantiqiy operatorlar ishlatiladi.

Bu matematik code gicrlash benchmarklarida.

GS M&K HumanEval testni oshiradi.

Residual Connection va Gradient Highway

NN da Normalizatsiya bolsakam gradientlar o'ziga tarqalayotganda yōqolib ketishi yoxi o'rganish to'xtashi mumkin.

Residual Connection (Qo'liq Bog'lanish)

Bu Gradient Magistrali (Gradient Highway)

Input $x \rightarrow$ Attention yoki FFN qatlaridan o'tishi kerak. Odatda NN ish qatlarlaridan nimadurmi o'rganadi.

Input $x \rightarrow + f(x) \rightarrow \text{output } (x + f(x))$

Nega bu Highway? Gradientlar NN traia uchun o'ziga qaytaribboradi bu chiziq o'ziga to'g'ridan to'g'ri tirbandir va haddiganday qisqa matematik amallarni eng buyi tayanga yetib boradi. Bu magistral gradient sonishi butunlay yōqoladi.

Xulosa.

NN netn bilan ishlay olmaydi. uste va rope
(RoPe) ID larini uzluksiz float vektorlarga
aylantiradi.

Zamonaviy LLM normalizatsiya uchun, RMS
Activation uchun Sigmoid va position
Örni uchun RoPe arxitekturasiga tiliq
itdi. Samarali va tezrog.

Residual Connection esa NN train inqariga