

11 Dars.

Model Inson tilidagi sozlarni to'g'ridan to'g'ri fushunmaydi. Ish jarayoni matnni mayola. belarlarga tokenlarga ajratishdan boshlanadi.

→ Tokenization → Matn belgilangan lugat asosida sonli ID larga o'tkaziladi.

→ Token Embedding →: Harbi token soni ko'p o'lchamli faqatda vektor shakliga keltiriladi. gpt-2 har bir tokenni 768 o'lchamli vektor bilan ifodalaydi.

→ Positional Embedding → Sozlarning ketma ketligi va tartibi manovi butunlay o'zgartiriladi. Osh Pishali va Pishali Osh.

→ RoPE → Zamonaviy modellarda (Llama, Mistral) vektorlar burchak ostida beriladi.

Attention Mexanizmi

Transformer modelini yuzagi. U matndagi sozlarni bir biriga bog'ligini o'rganadi.

Q K. V

Query Ibray token nimani qidirayotgani.

Key Boshqa tokenlar qanday kalit ma'lumot beradi?

Value Token haqiqiy Kaxi

GPT-2 modelida 12 ta Attention Head
bor parallel ishlaydi. Har bir head
64 o'lchamli fazoda aloxida mantiqiy bog'likni
ishlaydi. $12 \times 64 = 768$

Bitta matni 12 ta mutaxassis bir vaqtida
tekshiradi. Yacunda barcha taxlillar bizlarga

Modellarning javob qaytarish tesligi va xotira
VRAM sarfi ~~diqqat~~ Attention arxitekturasiga
tutqiga bog'liq.

MHA. (Har bir Query head uchun Alohiola
Key va Value head mavjud. Xotira sarfi yuqori
hisoblanadi secinmoq.

MQA. Barcha Querylar uchun faqat bitta
umumiy Key va Value head ishlatiladi.

Xotira sig'ati keskin kamayadi. tezlik oshadi.

GQA. MHA va MQA o'rtasidagi oltin o'rta
Query headlar guruhlarida har bir guruh
alohida KV headga birlashtiriladi.

MHA 12 ta jurnalist har birini aloxida
tasvirlash bor

MQA 12 ta jurnalist bitta umumiy tasvirlashga ega

GQA 12 ta jurnalist yig'uvchi birlashtirib

har bir guruh aloxida tasvirlashga ega.

Axborotni Aqyl ishlash tarasigi

tarasig bargavarligi.

FFN nima va u nima ish qiladi

Attention mexanizmi kontekstdagi sozlar o'tasidagi oloq va munosabatni o'rnatib FFN har bir tokenning ichki manosi ni chugunlashtiradi va boyitadi.

Transformer model nima $\rightarrow$ bu matn va mab-motlarni birma bir (idna-ket) emas butunidaq va bir vaqtning o'zida parallel tahlil qilib sozlar o'tasidagi mantiqiy bog'liqlikni taqizlaydigan zamonaviy NN arxitekturas.

Bugun ChatGPT, Gemini, Claude, Llama, va boshqa zamonaviy AI modellari aynan shu Transformer paydalan.

Eski model va Transformer o'tasidagi farq.

RNN - LSTM: Matni xudoli o'qib sozlar soz chopdan o'ng qaratib o'giz

Bir gap oxirasi yetgunda gap baki o'giz. sozlar xotiradan diqib o'giz. parallel ishlash bilmaz edi.

Transformer modelda chugurlashgan sari masalan (12, 32, 36 ta layerda) to'g'ri topshirilmagan ma'lumotlarni yozguncha, bu masalada va taimoqni dalolat beradi. chugurlashgan eng katta miqdorga aylantiradi.

NN ichki muvaznati saqlaydigan vira beriladi, o'zgarib o'tayotgan barcha qismlar, eng muhim 4 ta arxitektura turlaridan biri.

Residual Connection

NN chugurlashgan sari train vaqtida xato, signallarning o'tish qoralar, back propagation davomida gradientlar, davomiy gradientlar e'loni kamayib boradi. vanishing gradient. Natijada do'zlikni qat'iy hech narsa o'zgarish qat'iy.

Yechil: Kiruvchi signalni (x) bloc ichida qayta ishlatish bilan birga blocni aylantirib o'tadigan qisqa yol orqali to'g'ridan to'g'ri qat'iy.

Pre-layer Norm Eski Transformerlardan normalizatsiya bloklaridan keyin qo'llanilgan PostLN. Zamonaviy modelda 4 bloklarga kiritish qat'iy. Pre LN Bu signal blokiga kiritilgan, chugurlashgan masalada bir necha keltirilgan. va o'zgarish.

Asosiy Blok ATTention Layer. (Shaxar ichi tiliq, va svelagan kodlar)

Residual Connection. 62 years experience

Layer Norm $\Rightarrow$ RMS Norm

Normallik ödəyən sənələr qiyaslı
kəskin kəskinləşməni yoxa çıxır. Kəskinləşmə
kəskinləşmə model portlaydı. Normalizasiya bəzi
vektor sənələri bir xil standartlaşdırma, orqan
kəskinləşmə tərzi.

Layer Norm genday ishlaysi

Vektorning o'rtacha qiymati (μ) va dispersiyasi σ^2 hisoblaydi, shuningdan bir elementdan o'rtacha qiymatni ayirib standart og'irlik bo'ladi.

RMS Norm olmalarını paygahıdır verilerin öte
gignatur aygıt otizid short end?

Fogat gina kvachatie ibole boji ora mashtake,
ham ovaigli zaracha treshmoye.

Lager Norm singlari ker bir o'g'irani baxosing yig'ib
 siraing sira baxosini to'g' ker bir o'g'irani
 baxosini o'tama baxosini o'g'irani

RMSKer o'ladan bo'ldi, tog'ida uning baxosi
kuchli o'zlashtirish qare kashak tashlab
beradigan chongon tashlab.

Activation Function Geli $\rightarrow$ Swigla.
NN ga non linearity va mantiqiy filtrlash
qobiliyatini beruvchi Matematik fkt?

Geli $\rightarrow$ Musbat Sanlarni o'tirish, manfiylar esa
nolga kashin aylantirish, sillig egri chiziq
bila o'ziga qaytishni o'tirish GPT-2.

Swigla $\rightarrow$ Jaded mexanizm. U bizni o'ziga
qaytishni o'tirish. Mantoy Bitta yol xk, data
olib o'tsa. 2 yol Swish ($x \cdot \text{kg}$) aqillik tashvish
bizni yoldan kelgan o'tirish, psixi bizi
necha qaytishni o'tirish belgilash ber.